Laporan Akhir Pemodelan Machine Learning

Deteksi Kecurangan Transaksi Kartu Kredit Menggunakan Ensemble Learning

Muhammad Nazwar Fakhrurrozy | NRP. 5054251040

---

1. Pendahuluan dan Analisis Eksplorasi Data

Laporan ini menyajikan analisis dan implementasi model Machine Learning untuk mendeteksi transaksi kartu kredit yang terindikasi kecurangan (fraud). Dataset yang digunakan berisi 284.807 transaksi dengan 31 kolom awal, mencakup kolom Time, V1 hingga V28 (hasil transformasi PCA), Amount, dan label Class.

Kategori Kelas	Jumlah Transaksi	Persentase
Kelas 0 (Normal)	284.315	99,827%
Kelas 1 (Fraud)	492	0,173%
Total Data	284.807	100,000%

Ketimpangan kelas yang sangat ekstrem ini menjadi tantangan utama. Model yang dilatih tanpa penanganan khusus cenderung mengabaikan kelas minoritas, sehingga diperlukan strategi evaluasi dan pra-pemrosesan yang tepat.

2. Rekayasa Fitur dan Pra-pemrosesan Data

Untuk meningkatkan daya pembeda model terhadap pola kecurangan, dilakukan ekstraksi fitur agregat melintasi kolom transformasi V1 hingga V28.

1. Fitur statistik linier: penambahan nilai total (V_Sum), nilai rata-rata (V_Avg), serta simpangan baku (V_Std).
2. Fitur rentang ekstrem: penentuan nilai minimum (V_Min), nilai maksimum (V_Max), dan selisih absolut rentang (V_Range).
3. Fitur sebaran tanda: penghitungan jumlah nilai positif (V_Pos) dan jumlah nilai negatif (V_Neg).

Proses ini menambah 8 fitur baru sehingga total variabel independen menjadi 38 kolom. Seluruh fitur independen kemudian diskalakan menggunakan RobustScaler untuk meminimalkan pengaruh pencilan (outlier) ekstrem pada variabel transaksi. Data dibagi menjadi data latih (80%) dan data uji (20%) secara terstratifikasi (stratify=y) guna mempertahankan proporsi kelas asli.

3. Pemodelan Ensemble dan Resampling

Sistem klasifikasi dibangun menggunakan teknik komputasi gabungan (Ensemble Soft Voting) dari tiga algoritma Gradient Boosting:

1. CatBoost Classifier (bobot prediksi: 0,35)
2. XGBoost Classifier (bobot prediksi: 0,35)
3. LightGBM Classifier (bobot prediksi: 0,30)

Pengujian dilakukan dalam dua skenario utama untuk mengukur dampak penanganan imbalansi kelas:

1. Skenario A: Pelatihan ensemble langsung pada data asli tanpa resampling.

2. Skenario B: Pelatihan ensemble pada data latih yang telah diseimbangkan menggunakan teknik Synthetic Minority Over-sampling Technique (SMOTE), di mana jumlah sampel kelas 1 disamakan menjadi 227.451 data.

4. Evaluasi dan Perbandingan Hasil

Evaluasi kinerja model dilakukan pada data uji independen sebanyak 56.962 transaksi (terdiri dari 56.864 transaksi normal dan 98 transaksi fraud).

Metode Pemodelan	Precision	Recall	F1-Score	AUC-ROC
Ensemble Tanpa Resampling	0,9080	0,8061	0,8541	0,9745
Ensemble Dengan SMOTE	0,6567	0,8980	0,7586	0,9799

Analisis Perbandingan:

1. Ketepatan Prediksi (Precision): Model tanpa resampling menghasilkan tingkat kepastian yang lebih tinggi (90,80%), meminimalkan alarm palsu pada transaksi normal.
2. Sensitivitas Deteksi (Recall): Penerapan SMOTE meningkatkan sensitivitas deteksi kecurangan dari 80,61% menjadi 89,80%, yang berarti lebih banyak transaksi fraud yang berhasil ditangkap.
3. Keseimbangan (F1-Score): Model tanpa resampling unggul dalam keseimbangan umum dengan nilai F1-Score sebesar 0,8541 dibandingkan skenario SMOTE sebesar 0,7586.

5. Kesimpulan dan Rekomendasi

1. Pemodelan ensemble berbasis CatBoost, XGBoost, dan LightGBM terbukti efektif dalam memprediksi transaksi fraud dengan skor AUC-ROC di atas 0,97.
2. Pemilihan skenario terbaik bergantung pada prioritas bisnis sistem keuangan. Jika fokus utama adalah meminimalkan kerugian finansial akibat transaksi bodong yang lolos, skenario dengan SMOTE lebih direkomendasikan karena mencapai Recall sebesar 89,80%.
3. Jika fokus utama adalah menjaga kenyamanan pengguna dari pemblokiran kartu secara salah (false positive), skenario tanpa resampling merupakan pilihan optimal dengan Precision mencapai 90,80%.