Laporan Preprocessing Dataset House Prices

Muhammad Nazwar Fakhrurrozy (5054251040) || Dataset: Kaggle House Prices (Ames, Iowa)

---

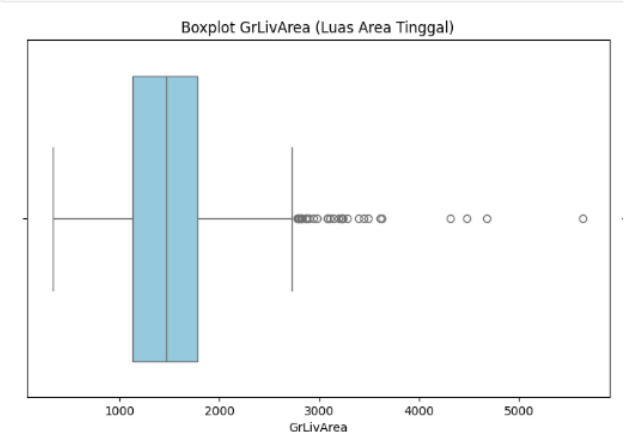
1. Ringkasan Proses dan Statistik Dataset

Laporan ini berisi ringkasan hasil pembersihan data (*data cleaning*), analisis nilai ekstrem (*outliers*), serta transformasi fitur dari dataset *House Prices* (Ames, Iowa). Dataset awal memiliki **1.460 baris** dan **81 kolom**. Proses *cleaning* diawali dengan mengidentifikasi persentase nilai hilang (*missing values*). Fitur dengan nilai hilang di atas 50% (`PoolQC`, `MiscFeature`, `Alley`, `Fence`, dan `MasVnrType`) dieliminasi dari dataset. Fitur kategorikal tersisa diimputasi menggunakan nilai `'None'`, sedangkan fitur numerik seperti `LotFrontage` diimputasi menggunakan *median* berdasarkan kelompok `Neighborhood`. Berikut adalah ringkasan statistik deskriptif dari fitur numerik utama sebelum dilakukan perlakuan *capping*:

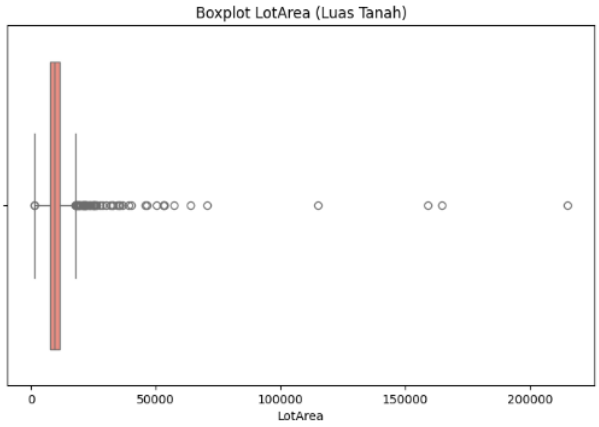
Fitur	Mean	Median	Std Dev	Min	Max
GrLivArea	1.515,46	1.464,00	525,48	334,00	5.642,00
TotalBsmtSF	1.057,43	991,50	438,70	0,00	6.110,00
LotArea	10.516,83	9.478,50	9.981,26	1.300,00	215.245,00
SalePrice	180.921,20	163.000,00	79.442,50	34.900,00	755.000,00

2. Distribusi Fitur Numerik Utama dan Outlier

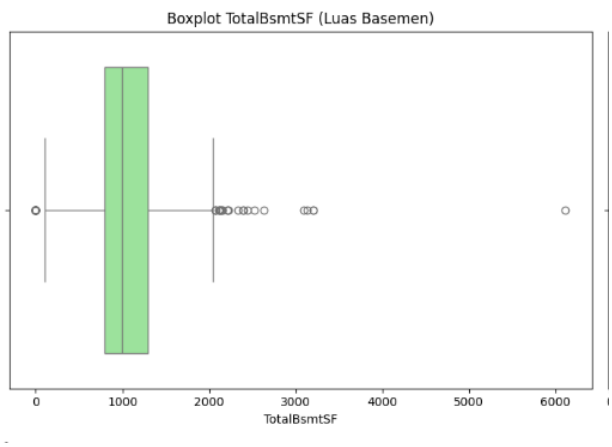
Visualisasi *boxplot* di bawah menunjukkan sebaran data serta kehadiran nilai pencilan (*outliers*) pada fitur `GrLivArea`, `LotArea`, `TotalBsmtSF`, dan `SalePrice`. Untuk mengatasi pencilan ekstrem tanpa menghapus baris observasi, diterapkan metode **IQR Capping** dengan memangkas nilai di luar batas rentang $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$.



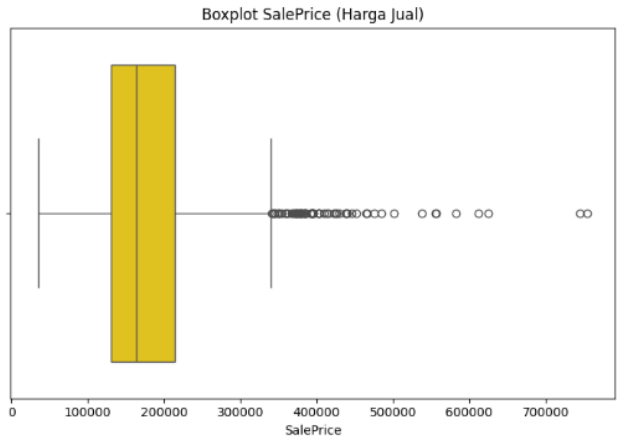
Gambar 1: Boxplot GrLivArea (Luas Area)



Gambar 2: Boxplot LotArea (Luas Tanah)



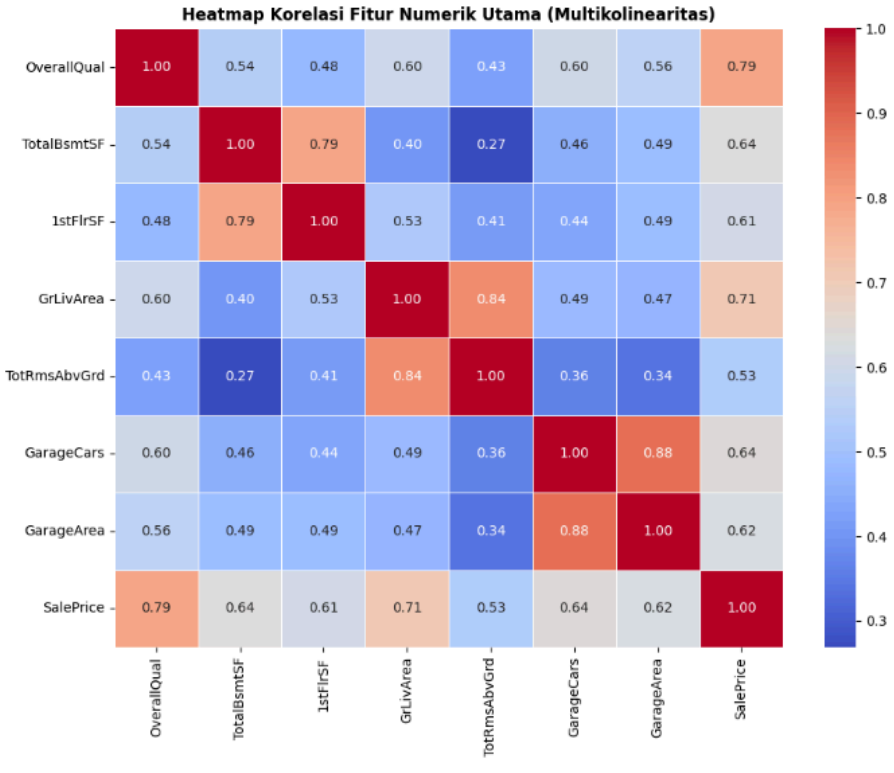
Gambar 3: Boxplot TotalBsmtSF (Basemen)



Gambar 4: Boxplot SalePrice (Harga Jual)

3. Korelasi dan Multikolinearitas Fitur

Berdasarkan *heatmap* korelasi, kualitas keseluruhan rumah (`OverallQual`, $r = 0,79$) dan luas area tinggal di atas tanah (`GrLivArea`, $r = 0,71$) merupakan prediktor dengan hubungan linier terkuat terhadap `SalePrice`. Selain itu, ditemukan indikasi multikolinearitas tinggi antar-prediktor, seperti pasangan `GarageCars` & `GarageArea` ($r = 0,88$) serta `GrLivArea` & `TotRmsAbvGrd` ($r = 0,84$).



Gambar 5: Heatmap Korelasi Fitur Numerik Utama

4. Transformasi Data dan Rekayasa Fitur

Setelah pembersihan data dan pemangkasan pencilan selesai, variabel kategorikal dikonversi menjadi fitur numerik dummy menggunakan *One-Hot Encoding* (`pd.get_dummies(drop_first=True)`), yang memperluas dimensi dataset dari 76 kolom menjadi **245 kolom**. Selanjutnya, seluruh fitur numerik diskalakan menggunakan `StandardScaler` agar memiliki nilai rata-rata 0 dan varians 1.

5. Kesimpulan dan Rekomendasi

Dari hasil eksplorasi dan *preprocessing* yang telah dilakukan, dataset telah siap sepenuhnya untuk tahap pemodelan (*zero missing values* dan skala seragam). Dikarenakan dimensi data meningkat menjadi 245 fitur serta terdapat multikolinearitas pada beberapa variabel utama, disarankan untuk menerapkan **Principal Component Analysis (PCA)** sebagai langkah reduksi dimensi sebelum melatih model *Machine Learning* seperti *Ridge Regression*, *Random Forest*, atau *XGBoost*.